项目技术说明文档 · PROJECT DOCUMENTATION

Prism

LLM 能力开放平台：对外完全 OpenAI 兼容，对内实现多模型路由与故障转移、Redis+Lua 令牌桶限流、语义缓存、Token 计量计费与配额管控，内置 LangChain RAG 与 ReAct Agent。Java 微服务做工程底座，Python 做 AI 编排。

作者：夏梦楠 · 2026 年 10 月 ·

github.com/purely628

SPRING CLOUD GATEWAY / WEBFLUX / REDIS / LANGCHAIN

PRISM

目 录

一、项目定位 2
二、架构总览 2
三、核心技术设计 2
3.1 网关层：鉴权与令牌桶限流 2
3.2 语义缓存 3
3.3 多渠道路由与故障转移 3
3.4 WebFlux SSE 流式透传 3
3.5 异步计量与一致性 3
3.6 跨语言 RAG 编排 3
四、数据模型（MySQL prism 库） 4
五、快速开始（local 模式） 4
六、实测验收记录（2026-10-11 真实运行） 4
七、已知边界与演进方向 5

一、项目定位

Prism 是一个 LLM 能力开放平台（AI 中台网关）：对外提供完全 OpenAI 兼容的 /v1/chat/completions 接口，客户端只需把 base_url 与 API Key 换成 Prism 即可接入；对内实现多模型渠道路由与故障转移、Redis+Lua 令牌桶限流、语义缓存降本、Token 计量计费与月度配额管控，并内置 LangChain RAG 知识库问答（引用溯源）与 ReAct Agent 工具调用能力。

选型动机：企业接入大模型的真痛点不在调通 API，而在接入之后的治理——密钥、限流、成本、多模型切换、知识库统一。Java 微服务做工程底座，Python/LangChain 做 AI 编排，对应企业里业务中台与 AI 编排服务的真实分工；相对市面常见的商城/秒杀类项目，该题目在校招简历中几乎不撞车。

二、架构总览

模块	端口	职责	技术栈
prism-gateway	8080	JWT/API Key 鉴权、Redis+Lua 令牌桶限流、路由转发、SSE 透传、内网保护	Spring Cloud Gateway (WebFlux)
prism-user	8101	账号、应用与 API Key 生命周期、模型渠道管理、种子数据	Boot MVC + MyBatis-Plus + BCrypt
prism-chat	8102	OpenAI 兼容推理：配额预检、语义缓存、加权路由+故障转移、SSE 流式透传、用量事件	Boot WebFlux + Caffeine + Redis
prism-billing	8103	用量消费（幂等/攒批）、月配额计数、每日对账、月度账单、看板聚合	Boot MVC + Redis Stream/RabbitMQ
prism-kb	8104	知识库/文档管理、解析任务派发、解析回调落库、检索与 RAG 代理（SSE 透传）	Boot MVC + JDK HttpClient
agent-service	8200	文档解析入库（切分/embedding/Chroma）、RAG 问答、ReAct Agent	FastAPI + LangChain + Chroma
frontend	5173/80	控制台 10 页面：仪表盘/应用/渠道/用量/知识库/RAG/Playground/Agent	Vue3 + Vite + Pinia + Element Plus + ECharts

运行形态双轨：local profile 仅依赖 MySQL+Redis（MQ 以 Redis Stream 实现，含消费组/ACK/pending 认领语义），可离线跑通全链路；compose profile 一键拉起 Nacos、RabbitMQ、Nginx （静态托管 + 反代 + SSE 不缓冲 + 接入层 limit_req）的完整生产拓扑。

三、核心技术设计

3.1 网关层：鉴权与令牌桶限流

- 双鉴权：/v1 走 API Key（Redis hash 存应用信息，miss 回源 user 服务回填）；/api 走 JWT （网关验签后透传 X-User-Id，并剥离外部伪造的同名头）。
- 令牌桶限流：Lua 脚本原子完成按流逝时间补令牌+扣减，key 为 prism:rl:{appKey}，rate 取应用速率、容量为 2 倍速率允许受控突发；集群安全（Redis 集中执行）。

• 错误语义分级：/v1 返回 OpenAI 风格 error 对象（429 rate_limit_error / 401 invalid_api_key），/api 返回统一 Result 结构；/internal 外部一律 403。

3.2 语义缓存

• prompt 归一化（去空白/转小写）后向量化：默认 512 维本地 bigram 哈希 TF 向量（离线可跑），可配置切换远程 embedding 服务（agent-service /embed）。

• 余弦相似度与该模型槽位全部缓存条目取最大，阈值 0.92 命中即回放，重复问答零上游成本；命中标记 cacheHit=true 进入看板统计。

• 已知边界：单机 Caffeine（256 条/1h TTL），多实例应下沉 Redis Hash；误命中风险通过保守阈值 + cacheHit 可观测 + 高风险场景跳过缓存缓解。

3.3 多渠道路由与故障转移

• 同名模型（alias）多渠道加权随机；渠道列表走 Redis 缓存（TTL 60s + 变更主动失效双保险）。

• 健康摘除：连续失败 3 次 INCR 计数（TTL 5min 到期自动恢复=半开），调用侧对上游 5xx/超时透明重试，最多换 2 个渠道。

3.4 WebFlux SSE 流式透传

• 全链路响应式：上游 delta 逐块转发的同时增量累计 token（CJK+1、其他/4，上游真实 usage 优先），流结束 doFinally 发布用量事件；不缓冲整包、不聚合响应体。

• 客户端断连 doOnCancel 取消上游订阅，止血省 token。

3.5 异步计量与一致性

• 用量事件走消息队列（local=Redis Stream MAXLEN 10000；compose=RabbitMQ 直连交换机+DLQ），推理主链路不被写库拖累。

• 消费端双重幂等：Redis SETNX(msgId) 快速去重 + t_usage_record 唯一索引兜底；幂等顺序为先查后置，落库前崩溃由重投+唯一索引吸收。

• 攒批入库：满 500 条或 2 秒批量 INSERT 削峰；账单是流水表的派生视图，出账前先对账。

• 对账：每日 02:30 按应用汇总 DB 流水 vs Redis 计数，diff 落 t_reconcile_diff 留痕并以 DB 为准覆写修正。

3.6 跨语言 RAG 编排

• Java 管编排与状态：上传白名单校验+路径穿越清洗，派发任务 {docId, kbId}，回调驱动状态机 PENDING-PARSING-READY/FAILED（chunks 先删后插幂等）。

• Python 管模型生态：RecursiveCharacterTextSplitter 中文分隔符优先切分，Chroma cosine 空间存储（uuid5 幂等 upsert），RAG 回答强制编号引用并回传 citations 事件。

• 可靠性：任务处理成功才 ACK，回调不可达留在 pending 重投；MockReActChatModel 走真实 AgentExecutor 循环，离线演示与真实 LLM 共用同一链路。

四、数据模型（MySQL prism 库）

表	关键字段/约束	说明
t_user / t_app	uk_username; uk_app_key; rate_limit/monthly_quota	控制台账号与接入应用（API Key=sk-prism-+32hex）
t_model_channel	idx_alias; weight/status	上游渠道：同 alias 加权随机
t_usage_record	uk_msg_id; (app_id, created_at); idx_time	用量流水：唯一索引是幂等最后防线
t_bill	uk_app_month	月度账单（流水派生视图，可重算）
t_reconcile_diff	idx_day	对账差异留痕（DB 为准覆写 Redis）
t_failed_message	—	毒消息/消费失败兜底
t_kb / t_document / t_doc_chunk	document 状态机; chunk (doc,kb) 索引	知识库域：向量在 Chroma，原文冗余存 MySQL

五、快速开始（local 模式）

```
mysql -h127.0.0.1 -uroot -p < sql/init.sql
mvn clean package -DskipTests
java -jar prism-user/target/prism-user-1.0.0.jar
java -jar prism-gateway/target/prism-gateway-1.0.0.jar
java -jar prism-chat/target/prism-chat-1.0.0.jar
java -jar prism-billing/target/prism-billing-1.0.0.jar
java -jar prism-kb/target/prism-kb-1.0.0.jar
cd agent-service && .venv/Scripts/uvicorn app.main:app --port 8200
cd frontend && npm i && npm run dev # admin / admin123
```

60 秒体验 OpenAI 兼容接口（内置 mock 渠道离线可跑）：

```
curl -N http://localhost:8080/v1/chat/completions \
 -H "Authorization: Bearer sk-prism-demo0000demo0000demo0000demo0000" \
 -H "Content-Type: application/json" \
 -d '{"model":"prism-demo","messages":[{"role":"user","content":"用一句话介绍你自己"
}],"stream":true}'
```

六、实测验收记录（2026-10-11 真实运行）

验收项	实测过程	实测结果
登录与 JWT	login admin/admin123 取 token，经网关访问 /api/apps	签发 HS384 JWT；应用列表含月已用 token 与配额进度

验收项	实测过程	实测结果
鉴权与内网保护	无 Key POST /v1；外部访问 /internal	401 invalid_api_key；403 拒绝
OpenAI 兼容 SSE	经网关流式请求 prism-demo 模型	逐块输出 chat.completion.chunk，末尾 usage+[DONE]
语义缓存	同 prompt 重复请求两次	第二次 cache_hit=1 落库（看板命中率 28.57%）
计量计费链路	XADD 造消息+真实调用事件	流水入库；summary 聚合 7 calls/843 tokens/按模型与 topApps 分组
对账修正	重复投递使计数器漂移 500 vs 250	reconcile diffCount=1，以 DB 为准覆写并留痕
RAG 全链路	上传 txt -> 解析 -> 检索 -> 流式问答	状态机 READY；检索 score=0.255；回答 102 字带引用溯源
ReAct Agent	goal 混合任务（检索+计算）	22 个 SSE 事件：thought/action(kb_search)/observation/answer
单测	mvn test + pytest	Java 68（user 13/chat 41/billing 7/kb 7）+ Python 28，全绿

七、已知边界与演进方向

已知边界	演进方案
单库多服务（user/billing/kb 共库）	按服务拆库；跨服务数据走事件快照字段或服务间查询+缓存
配额软限制（预检只看已用量）	预扣-确认-回补硬化（每请求两次 Redis 往返，演示场景收益不成比例）
语义缓存单机内存	下沉 Redis Hash 或专用向量库（接口已抽象，配置级改造）
Token 为估算	接入真实 tokenizer 离线校准系数；上游 usage 优先已实现
内网头信任模型	mTLS 或 HMAC 签名转发头；密钥 KMS 化
无监控体系	Prometheus 指标+traceId 贯穿网关到消费端